

Soru-SQL Eşleştirme için Embedding Modeli Karşılaştırması Case Raporu

1. Amaç

Kullanıcı sorularını, önceden hazırlanmış golden_queries setindeki doğru SQL ile eşleştirmek için en uygun embedding modelini bulmak amacıyla 6 model karşılaştırıldı: zorunlu referans (multilingual-e5-large), BAAI/bge-m3, iki Türkçe BERT modeli (emrecaan, selmanbaysan/trmteb), statik/distile bir model (atasoglu/1mb) ve bir bulut modeli (Cohere embed-multilingual-v3.0).

2. Veri Seti

golden_queries.json — 1.525 soru-SQL çifti. Hepsine id eklenip tespit edilen 5 duplicate çıkarıldı, 1.520 kayıtlı devam edildi.

3. Yöntem

Her model için, soru metinleri embed edilip FAISS ile indekslendi, cosine similarity ile arama yapıldı. Veri setindeki sorularla test etmek yanıltıcı olacağından, 100 soru seçilip paraphrase edildi ve bu 100 soru test seti olarak kullanıldı.

Ölçütler: Recall@1, Recall@3, MRR, ve ortalama sorgu süresi (ms).

4. Sonuçlar


Model	Recall@1	Recall@3	MRR	Ort. Süre (ms)
multilingual-e5-large (referans)	%88	%94	0.9083	78.10
BAAI/bge-m3	%83	%90	0.8650	82.38
emrecaan (Türkçe BERT)	%83	%94	0.8800	22.69
selmanbaysan/trmteb (Türkçe BERT)	%80	%91	0.8500	21.50
atasoglu/1mb-turkish-embeddings	%9	%21	0.1383	0.17
cohere embed-multilingual-v3.0 (bulut)	%89	%97	0.9300	7.91

5. Ram ve Maliyet

Yerel modellerin RAM kullanımı parametre sayısına göre tahmin edilmiştir; hepsinin API maliyeti sıfırdır, tek maliyeti çalıştıkları donanımdır. Cohere ise cihazda hiç RAM kullanmaz (bulutta çalışır), ancak token başına ücretlendirilir: \$0,10 / 1M token. Bu proje boyutu için (yaklaşık 60.000 token) maliyet 1 doların çok altında kalmıştır; üretim ölçeğinde (1 milyon canlı sorgu) tahmini maliyet ise yaklaşık \$3,40'tır.

6. Doğruluk-Hız Dengesi

Modeller sadece doğruluğa göre değil, doğruluk-hız dengesine göre de karşılaştırıldı. Recall@1 değeri %50'nin altında kalan modeller (atasoglu/1mb) pratik kullanım açısından yetersiz kabul edilip analiz dışı bırakıldı. Kalan modeller arasında birbirine göre hem daha yavaş hem daha az doğru olanlar elendi:



Cohere, hem en yüksek doğruluğa (%89) hem en düşük gecikmeye (7,91 ms) sahip olduğundan, eşiği geçen diğer tüm modelleri eldi. Ölçülen hız, 100 sorunun tek bir API çağrısında toplu gönderilmesiyle elde edildiği için gerçek, tekil kullanıcı sorgusundaki gecikme muhtemelen daha yüksek olacaktır.

Cohere'in çok dilli embedding modeli, düşük kaynaklı diller için farklı NLP görevlerinde de akademik literatürde tercih edilmiş ve başarılı sonuçlar vermiş, bu da modelin güvenilirliğine dair ek bir gösterge sunuyor.

7. Bulgular

- Cohere embed-multilingual-v3.0, hem doğruluk hem hız açısından en iyi sonucu verdi; ancak veri, üçüncü taraf bir sunucuya gönderildiği için gizlilik açısından ayrıca değerlendirilmesi gerekiyor. RAM tüketmemesi ek bir avantaj, ancak kullanım arttıkça token bazlı maliyeti birikir.
- Yerel modeller arasında referans model (multilingual-e5-large) en doğru, ama en yavaş ve en çok RAM tüketen model oldu.
- Türkçe-özel modeller (emrecaan, trmteb), boyut olarak çok daha küçük olmalarına rağmen yakın doğruluk + belirgin hız ve RAM avantajı sağladı — yerel/offline çalışmak gerektiğinde iyi bir orta yol.
- atasoglu/1mb aşırı hızlı ve neredeyse hiç RAM kullanmıyor, ama doğruluk kaybı kabul edilemez seviyede (%9 Recall@1), bu yüzden minimum doğruluk eşiğiyle analiz dışı bırakıldı.

8. Sonuç ve Öneri

Doğruluk, hız, RAM ve maliyet bir arada değerlendirildiğinde Cohere embed-multilingual-v3.0 öne çıkmaktadır. Ancak veri gizliliği önemliyse, internet bağımlılığı istenmiyorsa ya da düşük donanımlı bir ortamda çalışmak gerekiyorsa, emrecaan veya selmanbaysan/trmteb düşük doğruluk kaybıyla iyi bir alternatif sunmaktadır.

9. Kaynaklar

Arabacı vd. (2018), Kelime Gömevi Yöntemi Kullanarak Benzer Cümle Tespiti — Top-N doğruluk metodolojisi için referans.

Çizmeci & Gencer (2025), Türkçe ve İngilizce Dil Modellerinin Karşılaştırmalı Performans Analizi — çoklu metrik karşılaştırma yaklaşımı için referans.

Khalid, A. A., Borodo, S. M. & Abubakar, A. I. (2026). Leveraging CoHere Multilingual Embeddings and Inverted Softmax Retrieval for Automatic Parallel Sentence Alignment in Low-Resource Languages. Proceedings of the 7th Workshop on African Natural Language Processing (AfricaNLP 2026).